Problem 2: Connecting Attacks and Testing

adversarial attack과 DeepXplore 같은 테스트 도구는 밀접하게 관련되어 있다. 두 방법 모두 신경망의 약점을 드러내는 것을 목표로 하기 때문이다. 차이가 있다면 직접적인 목표에 있다. FGSM이나 PGD 같은 적대적 공격은 일반적으로 작은 교란(perturbation)을 통해 모델이 오분류하도록 만드는 데 초점을 둔다. 반면 DeepXplore는 differential behavior와 neuron coverage를 최대화하여 의심스러운 입력을 체계적으로 찾으려 한다. 이러한 목표는 서로 보완적이므로, 두 방법을 결합하는 것은 자연스러운 방향이다.

한 가지 유용한 결합 방식은 적대적 예제를 differential testing의 seed input으로 사용하는 것이다. 깨끗한 원본 이미지에서만 시작하는 대신, DeepXplore가 FGSM이나 PGD로 생성된 예제에서 시작할 수 있다. 이러한 입력은 일부 모델의 취약한 영역으로 빠르게 이동하게 해줄 가능성이 높기 때문에, 여러 모델 사이의 불일치를 더 쉽게 유도할 수 있다. 특히 모델들이 서로 다른 랜덤 seed, epoch 수, 하이퍼파라미터로 학습되었다면 이러한 경향은 더 강해진다. 이런 점에서 공격 기법은 테스트를 더 빠르게 만들어 줄 수 있으며, 탐색을 모델이 불안정한 영역으로 곧바로 이동시킬 수 있다.

반대 방향의 결합도 흥미롭다. DeepXplore의 coverage 지표를 공격 기법의 가이드로 사용할 수 있기 때문이다. 전통적인 공격은 주로 분류 손실(classification loss)을 최대화하는 방향으로 최적화되지만, coverage-guided attack은 오분류뿐 아니라 뉴런 활성의 다양성까지 함께 최적화할 수 있다. 이렇게 하면 단순히 모델을 속이는 입력이 아니라, 충분히 테스트되지 않은 내부 동작을 더 많이 탐색하는 입력을 만들 수 있다. 이러한 접근은 기존 공격이 놓칠 수 있는 실패 사례를 발견하는 데 도움이 될 수 있다. 예를 들어 최종 예측이 바로 바뀌지 않더라도, 내부 추론 과정이 비정상적이거나 여러 모델 사이에서 매우 불일치하는 경우를 찾을 수 있다.

두 방법을 결합하면 효율성 측면에서도 장점이 있다. 순수한 differential testing은 비교적 안전한 입력 공간에서 많은 반복을 소비할 수 있고, 반대로 순수한 적대적 공격은 하나의 모델과 하나의 목적 함수에만 좁게 집중하는 경향이 있다. 하이브리드 방식은 공격의 gradient를 이용해 취약한 영역으로 빠르게 이동한 뒤, disagreement와 coverage 목표를 이용해 더 넓고 다양한 실패 사례를 탐색할 수 있다. 특히 오분류뿐 아니라 불안정한 내부 동작도 중요한 안전 필수 시스템에서는, 이런 방식이 더 짧은 시간 안에 더 많은 버그를 찾는 데 도움이 될 수 있다.

물론 한계도 있다. 첫째, 여러 목적을 동시에 최적화하면 과정이 더 복잡하고 불안정해질 수 있다. coverage 향상, disagreement 증가, 입력의 자연스러움 유지가 서로 충돌할 수 있기 때문이다. 둘째, 적대적으로 생성된 입력이 지나치게 인위적이 되면 현실적인 테스트 사례로서의 가치가 떨어질 수 있다. 셋째, 테스트 대상 모델들이 너무 비슷하다면 결합 방법을 사용하더라도 의미 있는 disagreement가 잘 나타나지 않을 수 있다. 마지막으로, 높은 neuron coverage가 항상 더 유용하거나 안전과 직접 관련된 실패 사례를 의미하는 것은 아니므로, coverage는 보조적인 휴리스틱으로 이해해야 한다.

종합하면, 적대적 공격과 DeepXplore는 경쟁 관계가 아니라 상호보완적인 도구로 보는 것이 적절하다. 공격 기법은 실패 영역에 빠르게 접근할 수 있는 gradient 기반 수단을 제공하고, 테스트 프레임워크는 더 넓은 탐색 목표와 모델 간 비교 분석을 제공한다. 따라서 두 접근을 결합한 방법은 각각을 단독으로 사용하는 것보다 신경망의 숨겨진 약점을 더 효과적으로 찾아낼 가능성이 크다.